





14/7/2026

TECH CHALLENGE

Fase 2 - Data Analytics



Grupo 63:

Amanda Marques da Silva
Arthur Prieto Dias
Daniela Aparecida Gomes Lima
Diego Batista Vieira Feitosa
Rhoney Décio Rodrigues Mathias

Sumário

1.	Apresentação	1
2.	Análise de Dados	1
3.	Relação entre as Características Físico-Químicas e a Qualidade	2
4.	Balanceamento das Classes e Preparação dos Dados	3
5.	Desenvolvimento e Comparação dos Modelos	3
6.	Interpretação das Variáveis Mais Importantes.....	5
7.	Implicações para o Negócio	6
8.	Limitações da Análise.....	6
9.	Conclusão Geral do Projeto	7
10.	Recomendações Finais	7
11.	Materiais Complementares	7

1. Apresentação

A qualidade do vinho representa um dos principais fatores de competitividade da indústria vitivinícola. Tradicionalmente, essa avaliação depende da análise sensorial realizada por especialistas, processo que demanda tempo, experiência e apresenta elevado grau de subjetividade.

Nesse contexto, este projeto busca responder à seguinte questão:

“É possível prever, por meio das características físico-químicas do vinho, se um produto será classificado como de alta qualidade antes mesmo da avaliação sensorial, permitindo antecipar decisões de controle de qualidade durante o processo produtivo?”

Para responder essa pergunta foi utilizada uma base pública contendo informações laboratoriais de diferentes amostras de vinho. A partir desses dados foi desenvolvido um modelo de Machine Learning capaz de classificar automaticamente vinhos de Alta Qualidade (nota ≥ 7) e Baixa/Média Qualidade (nota < 7).

2. Análise de Dados

A base analisada contém 1.143 amostras de vinhos e 11 variáveis físico-químicas relacionadas ao processo de produção:

- Acidez fixa (fixed acidity);
- Acidez volátil (volatile acidity);
- Ácido cítrico (citric acid);
- Açúcar residual (residual sugar);
- Cloretos (chlorides);
- Dióxido de enxofre livre (free sulfur dioxide);
- Dióxido de enxofre total (total sulfur dioxide);
- Densidade (density);
- pH;
- Sulfatos (sulphates);
- Teor alcoólico (alcohol);
- Qualidade do vinho (quality).

Durante a etapa de preparação verificou-se que a base apresenta boa qualidade, não sendo identificados valores ausentes ou registros duplicados que comprometessem as análises. Entretanto, observou-se um desbalanceamento importante entre as classes, sendo a maioria dos registros composta por vinhos classificados como baixa ou média qualidade.

Essa característica representa um desafio para modelos de classificação, uma vez que algoritmos treinados sem tratamento adequado tendem a favorecer a classe predominante.

<u>Distribuição da Qualidade</u>		
Qualidade	Quantidade	% Por Qualidade
3	6	0,5%
4	33	2,9%
5	483	42,3%
6	462	40,4%

7	143	12,5%
8	16	1,4%


Aproximadamente 82,7% dos vinhos concentram-se nas notas 5 e 6, evidenciando uma predominância de vinhos classificados como de baixa ou média qualidade. Essa distribuição justifica a adoção de uma classificação binária, considerando vinhos com nota ≥ 7 como de alta qualidade e notas inferiores como de baixa/média qualidade. Essa abordagem simplifica o problema para um modelo de classificação binária e está alinhada à distribuição observada na base de dados.

3. Relação entre as Características Físico-Químicas e a Qualidade

A análise exploratória permitiu identificar padrões importantes entre as variáveis analisadas e a qualidade final dos vinhos.

Conforme observado na matriz de correlação, o teor alcoólico apresentou a associação positiva mais relevante com a classificação de alta qualidade, indicando que vinhos com maior graduação alcoólica tendem a receber melhores avaliações. Em contrapartida, níveis elevados de acidez volátil demonstraram influência negativa na qualidade, sugerindo que o excesso desse componente compromete as características sensoriais do produto. Também foi observada contribuição positiva dos sulfatos, enquanto variáveis como densidade apresentaram relação inversa com a classificação de qualidade.

Esses resultados indicam que a qualidade do vinho não depende de um único fator, mas do equilíbrio entre diferentes características físico-químicas.



4. Balanceamento das Classes e Preparação dos Dados

Após a análise exploratória, os dados passaram por uma etapa de preparação para garantir que os modelos de *Machine Learning* fossem treinados em condições adequadas e apresentassem resultados confiáveis.

Um dos principais desafios identificados foi o desbalanceamento entre as classes de qualidade. A base de dados era composta por aproximadamente 71,5% de vinhos classificados como baixa ou média qualidade e 28,5% de vinhos de alta qualidade. Essa distribuição é coerente com a realidade da indústria vitivinícola, na qual produtos considerados de alta qualidade representam naturalmente uma parcela menor da produção.

Embora essa característica reflita o contexto do negócio, ela pode influenciar negativamente o aprendizado dos modelos. Quando uma classe é muito mais frequente que a outra, o algoritmo tende a priorizar os padrões da classe predominante, reduzindo sua capacidade de identificar corretamente os casos menos frequentes. No contexto deste projeto, isso significaria um modelo eficiente para reconhecer vinhos comuns, porém com menor capacidade de identificar os vinhos de alta qualidade, que representam o maior interesse para o processo de tomada de decisão.

Para minimizar esse efeito, foi utilizada a estratégia de ponderação das classes (*class weights*). Em vez de alterar a base de dados por meio da duplicação ou remoção de registros, essa abordagem orienta o algoritmo a atribuir maior importância aos exemplos da classe minoritária durante o treinamento. Dessa forma, o modelo passa a aprender de maneira mais equilibrada, considerando adequadamente tanto os vinhos de alta quanto os de baixa qualidade, preservando integralmente as informações originais do conjunto de dados.

Essa estratégia foi escolhida por manter a representatividade da base e garantir que o modelo fosse desenvolvido sobre dados que refletem a realidade operacional da indústria. Além disso, por não modificar a composição da base, a solução torna-se mais transparente, de fácil interpretação e mais aderente ao cenário em que será aplicada.

Outra etapa importante da preparação consistiu na padronização das variáveis numéricas. Como as características analisadas são medidas em escalas diferentes, como teor alcoólico, acidez, densidade e pH, foi necessário colocá-las em uma mesma referência para que nenhuma variável exercesse influência excessiva apenas em função de sua unidade de medida. Esse procedimento permite que o modelo avalie cada característica pela sua contribuição real para a previsão da qualidade, e não pelo tamanho dos seus valores.

Ao final dessa etapa, os dados foram divididos em conjuntos de treinamento e teste, mantendo a proporção entre as classes em ambos os grupos. Essa prática assegura que o desempenho observado durante a avaliação represente, de forma consistente, o comportamento esperado quando o modelo for aplicado a novos dados.

Os resultados demonstraram a efetividade dessa preparação. Após o tratamento do desbalanceamento e a padronização das variáveis, o modelo passou a identificar com muito mais eficiência os vinhos de alta qualidade, elevando o *recall* de 34% para 77% e o *F1-Score* de 0,505 para 0,803. Esses ganhos indicam que o modelo não apenas aumentou sua capacidade de reconhecer os casos mais relevantes para o negócio, mas também manteve um equilíbrio entre precisão e sensibilidade, tornando suas previsões mais confiáveis para apoiar decisões relacionadas ao controle de qualidade e ao processo produtivo.

5. Desenvolvimento e Comparação dos Modelos

Foram avaliados dois algoritmos de classificação:

- Regressão Logística;
- Random Forest.

Os modelos foram treinados utilizando a mesma base de dados, permitindo comparação direta entre os resultados obtidos.


Embora ambos tenham apresentado desempenho satisfatório, o Random Forest demonstrou melhor capacidade de distinguir vinhos de alta qualidade, alcançando aproximadamente 85% de acurácia no conjunto de teste e resultados superiores nas principais métricas de avaliação quando comparado à Regressão Logística.


Além da maior acurácia, o modelo apresentou excelente capacidade discriminatória, evidenciada pelo elevado valor da curva ROC-AUC.

Esses resultados indicam maior robustez para utilização como ferramenta de apoio à decisão:

Modelo	Acurácia
Regressão Logística	76,97%
Random Forest	85,42%

Os resultados demonstram superioridade do modelo Random Forest para o problema analisado, justificando sua utilização como modelo principal do projeto.





6. Interpretação das Variáveis Mais Importantes


Além da elevada capacidade preditiva, o modelo permitiu identificar quais características exercem maior influência na classificação da qualidade.

As análises apontaram que teor alcoólico, acidez volátil, sulfatos e ácido cítrico estão entre os principais fatores utilizados pelo modelo para diferenciar vinhos de alta qualidade. Entre eles, o teor alcoólico apresentou a associação positiva mais relevante com a qualidade, enquanto a acidez volátil demonstrou influência negativa sobre a classificação final dos vinhos.

Sob a perspectiva do negócio, essas informações são especialmente relevantes, pois permitem direcionar ações de monitoramento e controle durante o processo produtivo.

Ao acompanhar continuamente essas variáveis, torna-se possível reduzir a variabilidade entre lotes e aumentar a probabilidade de obtenção de vinhos com classificação superior.

Importância das Features - Comparação dos Modelos



7. Implicações para o Negócio

Os resultados obtidos demonstram que modelos de Inteligência Artificial podem atuar como ferramenta de apoio ao processo decisório da indústria vitivinícola.

A utilização do modelo permite identificar antecipadamente lotes com maior probabilidade de atingir elevados padrões de qualidade, reduzindo custos associados a retrabalho, desperdícios e análises exclusivamente sensoriais.

Além disso, a identificação das variáveis mais relevantes possibilita maior controle do processo produtivo, contribuindo para:

- aumento da padronização entre safras;
- apoio à tomada de decisão dos enólogos;
- redução da variabilidade do produto;
- melhoria contínua da qualidade;
- maior eficiência operacional.

O modelo não substitui a avaliação humana, mas funciona como mecanismo complementar de apoio às decisões técnicas.

Além dos ganhos operacionais, a identificação antecipada dos fatores associados à qualidade permite ações preventivas ao longo do processo produtivo. Isso possibilita maior controle sobre os lotes produzidos e contribui para decisões mais orientadas por dados.

8. Limitações da Análise

Embora os resultados obtidos sejam consistentes, algumas limitações devem ser consideradas. A variável qualidade utilizada como referência foi atribuída por especialistas, estando sujeita à subjetividade inerente à avaliação sensorial. Além disso, o modelo foi desenvolvido exclusivamente com características físico-químicas, não contemplando fatores como aroma, sabor, processo de envelhecimento ou condições específicas de produção.

Por fim, novas bases contendo diferentes safras e regiões produtoras poderão aumentar ainda mais a capacidade de generalização do modelo.

9. Conclusão Geral do Projeto

- I. O estudo demonstrou que técnicas de Machine Learning podem prever a qualidade do vinho com elevado grau de confiabilidade utilizando apenas informações físico-químicas obtidas durante a produção.
- II. Entre os modelos avaliados, o Random Forest apresentou o melhor desempenho, alcançando aproximadamente 86% de acurácia e excelente capacidade de diferenciação entre vinhos de alta e baixa qualidade.
- III. Além da construção do modelo preditivo, o projeto permitiu identificar os principais fatores associados à qualidade final do produto, destacando teor alcoólico, acidez volátil, sulfatos e ácido cítrico como variáveis de maior relevância para a classificação dos vinhos e para o apoio à tomada de decisão na indústria vitivinícola.

Os resultados permitem responder afirmativamente à questão proposta. As análises demonstram que as características físico-químicas permitem prever, com elevado grau de confiabilidade, a classificação da qualidade antes da avaliação sensorial.

10. Recomendações Finais

- ✓ Utilizar o modelo como ferramenta de apoio na avaliação de novos lotes.
- ✓ Monitorar continuamente teor alcoólico, acidez volátil e sulfatos durante o processo produtivo.
- ✓ Atualizar periodicamente o modelo com novas safras para manter sua capacidade preditiva.
- ✓ Expandir a base de dados incluindo informações climáticas, variedades de uvas e processos de produção.
- ✓ Evoluir o modelo para previsão da nota completa do vinho, permitindo análises ainda mais detalhadas da qualidade.

11. Materiais Complementares

Como complemento deste projeto, são disponibilizados os materiais utilizados em seu desenvolvimento.

O vídeo executivo apresenta o problema de negócio, os principais achados da análise exploratória, o desempenho dos modelos de Machine Learning e os benefícios da solução proposta para a indústria vitivinícola.

Além disso, o repositório no GitHub reúne o notebook desenvolvido, os códigos-fonte e os demais arquivos utilizados na execução do projeto.

- O conteúdo pode ser acessado no link a seguir: https://youtu.be/6N_yJ7kLs5s
- Repositório GitHub: <https://github.com/rhoneymathias/tech-challenge-fase2>